

ANÁLISIS DISCRIMINANTE

El Análisis Discriminante Lineal (ADL o LDA) es una técnica estadística y de Machine Learning supervisado. Permite clasificar individuos (ej. clientes) en grupos preexistentes y descubrir qué variables (ej. edad, ingresos, estilo de vida) separan mejor a dichos grupos, maximizando las diferencias entre ellos.

Aplicaciones principales en IME

- **Segmentación y Perfiles de Clientes:** Identifica claramente qué características definen a tus "clientes leales" frente a los "ocasionales" o "desertores".
- **Predicción de Compra:** Clasifica a nuevos prospectos en categorías de compra probable (ej. "Comprador de alto valor" vs. "Comprador de bajo valor") basados en su perfil sociodemográfico.
- **Posicionamiento de Marca:** Ayuda a entender cómo perciben los consumidores las distintas marcas o productos, agrupándolos según sus preferencias.

ANÁLISIS DISCRIMINANTE TEORIA (Clasificación)

La discriminación o clasificación cuando conocemos los parámetros de las distribuciones admite una solución general. Un conjunto de elementos que pueden venir de dos o más poblaciones distintas. En cada elemento se ha observado una variable aleatoria p -dimensional x , cuya distribución se conoce en las poblaciones consideradas. Se desea clasificar un nuevo elemento, con valores de las variables conocidas, en una de las poblaciones.

El problema de discriminación aparece en muchas situaciones en que necesitamos clasificar elementos con información incompleta. En otros casos la información podría estar disponible, pero puede requerir destruir el elemento. Finalmente, en otros casos la información puede ser muy costosa de adquirir. Las técnicas que vamos a estudiar reciben también el nombre de clasificación supervisada.

Ejemplo 1.- Los sistemas automáticos de concesión de créditos implantados en instituciones financieras tienen que utilizar variables (ingresos, antigüedad en el trabajo, patrimonio, etc) para prever el comportamiento futuro.

Ejemplo 2.- En *reconocimiento de patrones* para diseñar máquinas capaces de clasificar de manera automática. Como, reconocer voces y sonidos, clasificar billetes o monedas, reconocer caracteres escritos en una pantalla de ordenador o clasificar cartas según el distrito postal.

Ejemplo 3.- Asignar un texto escrito de procedencia desconocida a uno de varios autores por las frecuencias de utilización de palabras, asignar una partitura musical o un cuadro a un artista, una declaración de impuestos como potencialmente defraudadora o no, un paciente como enfermo de cáncer o no, un nuevo método de fabricación como eficaz o no.

Análisis discriminante clásico debido a Fisher, basado en la normalidad multivariante de las variables y que es óptimo bajo dicho supuesto. Si todas las variables son continuas, es frecuente que aunque los datos originales no sean normales es posible transformar las variables para que lo sean, y los métodos pueden aplicarse a las variables transformadas. Cando se tiene variables discretas y continuas para clasificar, la hipótesis de normalidad multivariante es poco realista, Entonces necesitamos otros técnicas que pueden funcionar mejor en estos casos.

CLASIFICACIÓN ENTRE DOS POBLACIONES

Planteamiento del Problema

P_1 y P_2 dos poblaciones, $\mathbf{x}$ es una variable aleatoria vectorial, p-variante ($\mathbf{x}$ absolutamente continua). Las funciones de densidad de ambas poblaciones, f_1 y f_2 , son conocidas. Vamos a clasificar un nuevo elemento, $\mathbf{x}_0$ conocido, en una de estas poblaciones. Si conocemos las probabilidades a priori π_1 , π_2 , con $\pi_1 + \pi_2 = 1$, de que el elemento venga de una de las dos poblaciones, su distribución de probabilidad será.

$$f(\mathbf{x}) = \pi_1 f_1(\mathbf{x}) + \pi_2 f_2(\mathbf{x})$$

y una vez observado $\mathbf{x}_0$ podemos calcular las probabilidades a posteriori de que el elemento haya sido generado por cada una de las dos poblaciones, $P(i/\mathbf{x}_0)$, con $i=1,2$. Por el teorema de Bayes.

$$P(1|\mathbf{x}_0) = \frac{P(\mathbf{x}_0|1)\pi_1}{\pi_1 P(\mathbf{x}_0|1) + \pi_2 P(\mathbf{x}_0|2)}$$

y como $P(\mathbf{x}_0|1) = f_1(\mathbf{x}_0)\Delta\mathbf{x}_0$, tenemos que

$$P(1/\mathbf{x}_0) = \frac{f_1(\mathbf{x}_0)\pi_1}{f_1(\mathbf{x}_0)\pi_1 + f_2(\mathbf{x}_0)\pi_2},$$

y para la segunda población

$$P(2|\mathbf{x}_0) = \frac{f_2(\mathbf{x}_0)\pi_2}{f_1(\mathbf{x}_0)\pi_1 + f_2(\mathbf{x}_0)\pi_2}.$$

Clasificaremos $\mathbf{x}_0$ en la población más probable a posteriori. Como los denominadores son iguales, clasificaremos $\mathbf{x}_0$ en P_2 si:

$$\pi_2 f_2(\mathbf{x}_0) > \pi_1 f_1(\mathbf{x}_0)$$

Si las probabilidades a priori son iguales, la condición de clasificar en P_2 se reduce a:

$$f_2(\mathbf{x}_0) > f_1(\mathbf{x}_0)$$

es decir, clasificamos a $\mathbf{x}_0$ en la población más probable, o donde su verosimilitud es más alta.

Coste de Clasificación (consecuencias)

Si una máquina clasifica equivocadamente un billete de 10 euros como de 20, y devuelve el cambio equivocado, el coste de clasificación es de 10 euros. En otros casos estimar el coste puede ser más complejo.

Supondremos que las posibles decisiones en el problema son únicamente dos: asignar en P_1 o en P_2 . Una regla de decisión es una partición del espacio muestral $E_x (R^p)$ en dos regiones A_1 y $A_2 = E_x - A_1$, tales que:

si $x_0 \in A_1 \Rightarrow d_1$ (clasificar en P_1).


si $x_0 \in A_2 \Rightarrow d_2$ (clasificar en P_2).

Si las consecuencias de un error de clasificación pueden cuantificarse, como un problema bayesiano de decisión. Supongamos que:

1. Las consecuencias asociadas a los errores de clasificación son, $c(2/1)$ y $c(1/2)$, donde $c(i/j)$ es el coste de clasificación en P_i de una unidad que pertenece a P_j . Estos costes se suponen conocidos.
2. Se quiere maximizar su función de utilidad y esto equivale a minimizar el coste esperado.

Con estas dos hipótesis la mejor decisión es la que minimiza los costes esperados, o funciones de pérdida de oportunidad. Si clasificamos al elemento en el grupo 2 las posibles consecuencias son:

- a) acertar, con probabilidad $P(2/x_0)$, en cuyo caso no hay ningún coste de penalización;
- b) equivocarnos, con probabilidad $P(1/x_0)$, en cuyo caso incurrimos en el coste asociado $c(2/1)$.



El coste promedio (valor esperado), de la decisión; d_2 : clasificar x_0 en P_2 es:

$$E(d_2) = c(2|1)P(1|x_0) + 0P(2|x_0) = c(2|1)P(1|x_0).$$

El coste esperado de la decisión; d_1 : clasificar en el grupo 1 es:

$$E(d_1) = 0P(1|x_0) + c(1|2)P(2|x_0) = c(1|2)P(2|x_0).$$

Asignaremos el elemento al grupo 2 si su coste esperado es menor,

$$\frac{f_2(\mathbf{x}_0)\pi_2}{c(2|1)} > \frac{f_1(\mathbf{x}_0)\pi_1}{c(1|2)}.$$

Esta condición indica que, a igualdad de los otros términos, clasificaremos en la población P_2 si

- a) su probabilidad a priori es más alta;
- b) la verosimilitud de que x_0 provenga de P_2 es más alta;
- c) el coste de equivocarnos al clasificarlo en P_2 es más bajo.

Nota: este criterio es equivalente a minimizar la probabilidad total de error en la clasificación.

Poblaciones Normales: Función lineal discriminante

Sea f_1 y f_2 distribuciones normales con distintos vectores de medias pero idéntica matriz de varianzas. Se desea clasificar un elemento genérico $\mathbf{x}$, que si pertenece a la población $i=1,2$ tiene función de densidad:

$$f_i(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |V|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu_i)' V^{-1} (\mathbf{x} - \mu_i) \right\}.$$

La partición óptima, es, clasificar en la población P_2 si:

$$\frac{f_2(\mathbf{x})\pi_2}{c(2|1)} > \frac{f_1(\mathbf{x})\pi_1}{c(1|2)}.$$

Ambos términos son positivos, tomando logaritmos y sustituyendo $f_i(\mathbf{x})$

$$-\frac{1}{2}(\mathbf{x} - \mu_2)' V^{-1} (\mathbf{x} - \mu_2) + \log \frac{\pi_2}{c(2|1)} > -\frac{1}{2}(\mathbf{x} - \mu_1)' V^{-1} (\mathbf{x} - \mu_1) + \log \frac{\pi_1}{c(1|2)},$$

Llamando D_i^2 a la distancia de Mahalanobis entre el punto observado, $\mathbf{x}$, y la media de la población i :

$$D_i^2 = (\mathbf{x} - \boldsymbol{\mu}_i)' \mathbf{V}^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)$$

podemos escribir:

$$D_1^2 - \log \frac{\pi_1}{c(1|2)} > D_2^2 - \log \frac{\pi_2}{c(2|1)}$$

y suponiendo iguales los costes y las probabilidades a priori, $c(1/2) = c(2/1)$; $\pi_1 = \pi_2$, la regla anterior se reduce a:

$$\text{Clasificar en 2 si } D_1^2 > D_2^2$$

es decir, clasificar la observación en la población de cuya media esté más próxima, midiendo la distancia con la medida de Mahalanobis.

Observemos que si las variables $\mathbf{x}$ tuvieran $\mathbf{V} = I\sigma^2$, la regla equivale a utilizar la distancia euclídea.

Interpretación Geométrica

Debemos calcular la distancia de Mahalanobis, corregirla por el término correspondiente a las probabilidades a priori y los costes, y clasificar en la población donde esta distancia modificada sea mínima. Como las distancias tiene siempre el término común $\mathbf{x}'\mathbf{V}^{-1}\mathbf{x}$, que no depende de la población, podemos eliminarlo de las comparaciones y calcular el indicador

$$-\mu_i'\mathbf{V}^{-1}\mathbf{x} + \frac{1}{2}\mu_i'\mathbf{V}^{-1}\mu_i - \log \frac{\pi_i}{c(i|j)},$$

que será una función lineal en $\mathbf{x}$ y clasificar el individuo en la población donde esta función sea mínima. Esta regla divide el conjunto de valores posibles de $\mathbf{x}$ en dos regiones cuya frontera viene dada por:

$$-\mu_1'\mathbf{V}^{-1}\mathbf{x} + \frac{1}{2}\mu_1'\mathbf{V}^{-1}\mu_1 = -\mu_2'\mathbf{V}^{-1}\mathbf{x} + \frac{1}{2}\mu_2'\mathbf{V}^{-1}\mu_2 - \log \frac{c(1|2)\pi_2}{c(2|1)\pi_1},$$

que, como función de $\mathbf{x}$, equivale a:

$$(\mu_2 - \mu_1)'\mathbf{V}^{-1}\mathbf{x} = (\mu_2 - \mu_1)'\mathbf{V}^{-1} \left(\frac{\mu_2 + \mu_1}{2} \right) - \log \frac{c(1|2)\pi_2}{c(2|1)\pi_1}.$$

Llamando:

$$\mathbf{w} = \mathbf{V}^{-1}(\mu_2 - \mu_1)$$

La frontera se escribirse como: $\mathbf{w}'\mathbf{x} = \mathbf{w}'\frac{\mu_2 + \mu_1}{2} - \log \frac{c(1|2)\pi_2}{c(2|1)\pi_1}$

Que es la ecuación de un hiperplano. En el caso particular en que $c(1|2)\pi_2 = c(2|1)\pi_1$, clasificaremos en P_2 si.

$$\mathbf{w}'\mathbf{x} > \mathbf{w}'\left(\frac{\mu_1 + \mu_2}{2}\right) \dots\dots(1)$$

$$\mathbf{w}'\mathbf{x} - \mathbf{w}'\mu_1 > \mathbf{w}'\mu_2 - \mathbf{w}'\mathbf{x}$$

El procedimiento para clasificar un elemento x_0 puede resumirse como:

- 1) calcular el vector w
- 2) construir la variable indicadora discriminante (que transforma x en la variable escalar z).

$$z = \mathbf{w}'\mathbf{x} = w_1x_1 + \dots + w_px_p$$

- 3) calcular la variable indicadora para el individuo a clasificar, $x_0 = (x_{10}, \dots, x_{p0})$, con $z_0 = \mathbf{w}'x_0$ y el valor de la variable indicadora para las medias de las poblaciones, $m_i = \mathbf{w}'\mu_i$. Clasificar en aquella población donde la distancia $|z_0 - m_i|$ sea mínima.

En términos de la variable escalar z , como el valor promedio de z en P_i es :

$$\mathbf{E}(z|P_i) = m_i = \mathbf{w}'\mu_i, \quad i = 1, 2$$

La regla de decisión, equivale a clasificar en P_2 si: $|z - m_1| > |z - m_2|$

Esta variable indicadora, z , tiene varianza:

$$Var(z) = \mathbf{w}' Var(\mathbf{x}) \mathbf{w} = \mathbf{w}' \mathbf{V} \mathbf{w} = (\mu_2 - \mu_1)' \mathbf{V}^{-1} (\mu_2 - \mu_1) = D^2.$$

y el cuadrado de la distancia escalar entre las medias proyectadas es la distancia de Mahalanobis entre los vectores de medias originales:

$$(m_2 - m_1)^2 = (\mathbf{w}'(\mu_2 - \mu_1))^2 = (\mu_2 - \mu_1)' \mathbf{V}^{-1} (\mu_2 - \mu_1) = D^2.$$


z puede interpretarse como una proyección si estandarizamos el vector $\mathbf{w}$. Dividiendo (1) por la norma de $\mathbf{w}$ y llamando $\mathbf{u}$ al vector unitario $\mathbf{w}/|\mathbf{w}|$, la regla de clasificación se convierte en clasificar en P_2 si.

$$\mathbf{u}'\mathbf{x} - \mathbf{u}'\mu_1 > \mathbf{u}'\mu_2 - \mathbf{u}'\mathbf{x},$$

donde, al ser $\mathbf{u}$ un vector unitario, $\mathbf{u}'\mathbf{x}$ es simplemente la proyección de $\mathbf{x}$ en la dirección de $\mathbf{u}$ y $\mathbf{u}'\mu_1$ y $\mathbf{u}'\mu_2$ las proyecciones de las medias poblacionales en esa dirección.

En la figura se observa que el hiperplano perpendicular a u por el punto medio $u'(\mu_1 + \mu_2)/2$ divide el espacio muestral en dos regiones A_1 y A_2 que constituyen la partición óptima buscada. Si $c(1/2)\pi_2 \neq c(2/1)\pi_1$ la interpretación es la misma, pero el hiperplano frontera se desplaza paralelamente a sí mismo, aumentando o disminuyendo la región A_2 .

La dirección de proyección, $w = V^{-1}(\mu_2 - \mu_1)$ tiene una clara interpretación geométrica. Consideremos en primer lugar el caso en que las variables están incorreladas y estandarizadas de manera que $V = I$. Entonces, la dirección óptima de proyección es la definida por $\mu_2 - \mu_1$.



En el caso general, la dirección de proyección puede calcularse en dos etapas: primero, se estandarizan las variables de forma multivariante, para pasar a variables incorreladas con varianza unidad; segundo, se proyectan los datos transformados sobre la dirección que une las medias de las variables estandarizadas.


En efecto, el cálculo de $w'x$ puede escribirse como:

$$w'x = [(\mu_2 - \mu_1)'V^{-1/2}] (V^{-1/2}x)$$

donde $V^{-1/2}$ existe si V es definida positiva. Esta expresión indica que esta operación equivale a:

- (1) estandarizar las variables x pasando a otras $y=V^{-1/2}x$ que tienen como matriz de covarianzas la identidad y como vector de medias $V^{-1/2}\mu$;
- (2) proyectar las variables estandarizadas y sobre la dirección $\mu_2(y)-\mu_1(y)=(\mu_2 - \mu_1)'V^{-1/2}$.

En la figura. En (a) y (b) la dirección de la línea que une las medias coincide con alguno de los ejes principales de la elipse y por tanto la dirección $w=V^{-1}(\mu_2-\mu_1)$ coincide con $(\mu_2-\mu_1)$, ya que este es un vector propio de V , y por tanto también de V^{-1} . En (c) la dirección óptima es un compromiso entre $(\mu_2 - \mu_1)$ y las direcciones definidas por los vectores propios de V^{-1} . En los casos (a) y (b) la dirección óptima coincide con la línea de medias y con los ejes de la elipse. En el caso (c) es un compromiso entre ambos



Cálculo de Probabilidades de error

$z=w'x$ es normal, con media $m_i=w'\mu_i$ y varianza $D^2=(m_2-m_1)^2$, podemos calcular las probabilidades de clasificar erróneamente una observación en cada una de las dos poblaciones. La probabilidad de una decisión errónea cuando $x \in P_1$ es:

$$P(2|1) = P \left\{ z \geq \frac{m_1 + m_2}{2} \mid z \text{ es } N(m_1; D) \right\}$$

Sea $y=(z-m_1)/D$ variable aleatoria $N(0, 1)$, y Φ a su función de distribución:

$$P(2|1) = P \left\{ y \geq \frac{\frac{m_1+m_2}{2} - m_1}{D} \right\} = 1 - \Phi \left(\frac{D}{2} \right)$$

Análogamente, la probabilidad de una decisión errónea cuando $x \in P_2$ es:

$$P(1|2) = P \left\{ z \leq \frac{m_1 + m_2}{2} \mid z \text{ es } N(m_2; D) \right\} = P \left\{ y \leq \frac{\frac{m_1+m_2}{2} - m_2}{D} \right\} = \Phi \left(-\frac{D}{2} \right)$$

ambas probabilidades de error son idénticas, por la simetría de la distribución normal . Podemos concluir que la regla obtenida hace iguales y mínimas las probabilidades de error y que los errores de clasificación sólo dependen de las distancias de Mahalanobis entre las medias.

$$D^2=(u_2-u_1)' V^{-1} (u_2-u_1)$$

Probabilidades a posteriori

El grado de confianza al clasificar una observación depende de la probabilidad acertar. La probabilidad a posteriori de que la observación pertenezca a la primera población se calcula con :

$$\begin{aligned} P(1|\mathbf{x}) &= \frac{\pi_1 f_1(\mathbf{x})}{\pi_1 f_1(\mathbf{x}) + \pi_2 f_2(\mathbf{x})} \\ &= \frac{\pi_1 \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)' \mathbf{V}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) \right\}}{\left(\pi_1 \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)' \mathbf{V}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) \right\} \right) + \pi_2 \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)' \mathbf{V}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) \right\}} \end{aligned}$$

y llamando D^2_1 y D^2_2 a las distancias de Mahalanobis entre el punto y cada una de las dos medias, esta expresión puede escribirse:

$$P(1|\mathbf{x}) = \frac{1}{1 + \frac{\pi_2}{\pi_1} \exp \left\{ -\frac{1}{2}(D^2_2 - D^2_1) \right\}}$$

y sólo depende de las probabilidades a priori y de las distancias entre el punto y las medias de ambas poblaciones. Observemos que si $\pi_2/\pi_1=1$, cuanto más alejado está el punto de la primera población, es decir, cuanto mayor sea D_{21} respecto a D_{22} , mayor será el denominador y menor será la probabilidad de que pertenezca a ella, $P(1/x)$, y al contrario.

Ejemplo 1.- Se desea clasificar un retrato entre dos posibles pintores. Para ello se miden dos variables: la profundidad del trazo y la proporción que ocupa el retrato sobre la superficie del lienzo. Las medias de estas variables para el primer pintor, A, son (2 y 0.8) y para el segundo, B, (2.3 y 0.7) y las desviaciones típicas de estas variables son 0.5 y 0.1 y la correlación entre estas medidas es 0.5. La obra a clasificar tiene medidas de estas variables (2.1 y 0.75). Calcular las probabilidades de error.

Las distancias de Mahalanobis serán, calculando la covarianza como el producto de la correlación por las desviaciones típicas:

$$D_A^2 = (2.1 - 2, .75 - .8) \begin{bmatrix} .25 & .025 \\ .025 & .01 \end{bmatrix}^{-1} \begin{pmatrix} 2.1 - 2 \\ .75 - .8 \end{pmatrix} = 0,52$$

y para la segunda

$$D_B^2 = (2.1 - 2.3, .75 - .7) \begin{bmatrix} .25 & .025 \\ .025 & .01 \end{bmatrix}^{-1} \begin{pmatrix} 2.1 - 2.3 \\ .75 - .7 \end{pmatrix} = 0,8133$$

Por tanto, asignaremos la obra al primer pintor. El error esperado de clasificación con esta regla depende de la distancia de Mahalanobis entre las medias que es

$$D^2 = (2. - 2.3, .8 - .7) \begin{bmatrix} .25 & .025 \\ .025 & .01 \end{bmatrix}^{-1} \begin{pmatrix} 2. - 2.3 \\ .8 - .7 \end{pmatrix} = 2,6133$$

y $D=1.6166$. La probabilidad de equivocarnos es

$$P(A/B) = 1 - \Phi\left(\frac{1.6166}{2}\right) = 1 - \Phi(.808) = 1 - 0,8106 = 0,1894.$$

De manera que la clasificación mediante estas variables no es muy precisa, ya que podemos tener un 18,94% de probabilidad de error. Calculemos la probabilidad a posteriori de que el cuadro pertenezca al pintor A suponiendo que, a priori, ambos pintores son igualmente probables.

$$P(A/x) = \frac{1}{1 + \exp(-0.5(0,8133 - 0,52))} = \frac{1}{1.86} = 0,5376$$

Esta probabilidad indica que al clasificar la obra como perteneciente al pintor A existe mucha incertidumbre en la decisión, ya que las probabilidades de que pertenezca a cada pintor son semejantes (0,5376 y 0,4624).

GENERALIZACIÓN PARA VARIAS POBLACIONES NORMALES

Planteamiento General

Para G poblaciones: dividir el espacio E_x en G regiones $A_1, \dots, A_g, \dots, A_G$ tales que si x pertenece a A_i el punto se clasifica en la población P_i . Suponemos costes constantes y no depende de la población en que se ha clasificado. Entonces, la región A_g vendrá definida por aquellos puntos con máxima probabilidad de ser generados por P_g , es decir donde el producto de la probabilidad a priori y la verosimilitud sean máximas:

$$A_g = \{ \mathbf{x} \in E_x \mid \pi_g f_g(\mathbf{x}) > \pi_i f_i(\mathbf{x}); \forall i \neq g \}$$

Si las probabilidades a priori son iguales, $\pi_i = G^{-1}$, $\forall i$, y las $f_i(x)$ son normales con igual varianza, la condición equivale a la distancia de Mahalanobis del punto observado al centro de cada población y clasificarle en la población que haga esta distancia mínima. Minimizar las distancias de Mahalanobis $|\mathbf{x} - \mu_g|' \mathbf{V}^{-1} |\mathbf{x} - \mu_g|$ equivale, eliminando el término $\mathbf{x}' \mathbf{V}^{-1} \mathbf{x}$ que aparece en todas las ecuaciones, a minimizar el indicador lineal

$$L_g(\mathbf{x}) = -2\mu_g' \mathbf{V}^{-1} \mathbf{x} + \mu_g' \mathbf{V}^{-1} \mu_g.$$

y llamando

$$\mathbf{w}_g = \mathbf{V}^{-1} \mu_g$$

la regla es

$$\min_g (\mathbf{w}_g' \boldsymbol{\mu}_g - 2\mathbf{w}_g' \mathbf{x})$$

observamos que la frontera de separación entre dos poblaciones, (ij), viene definida por:

$$A_{ij}(\mathbf{x}) = L_i(\mathbf{x}) - L_j(\mathbf{x}) = 0$$

sustituyendo y reordenando los términos se obtiene:

$$A_{ij}(\mathbf{x}) = 2(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)' \mathbf{V}^{-1} \mathbf{x} + (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)' \mathbf{V}^{-1} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) = 0$$

y llamando $\mathbf{w}_{ij} = \mathbf{V}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) = \mathbf{w}_i - \mathbf{w}_j$

la frontera puede escribirse como: $\mathbf{w}_{ij}' \mathbf{x} = \mathbf{w}_{ij}' \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)$.

Esta ecuación admite la misma interpretación como proyección que en el caso de dos poblaciones. Se construye una dirección $\mathbf{w}_{ij}$ y se proyectan las medias y el punto $\mathbf{x}$ que tratamos de clasificar sobre esta dirección. La región de indiferencia es cuando el punto proyectado está equidistante de las medias proyectadas. En otro caso, asignaremos el punto a la población de cuya media proyectada esté más próxima.

Si tenemos G poblaciones sólo necesitamos encontrar $r = \min(G - 1, p)$ direcciones de proyección. Aunque podemos construir $\binom{G}{2} = G(G - 1)/2$ vectores w_{ij} a partir de las G medias, una vez que tenemos $G-1$ vectores los demás quedan determinados por éstos. Podemos determinar los $G-1$ vectores $w_{i,i+1}$, para $i=1, \dots, G-1$, y obtener cualquier otro a partir de estas $G-1$ direcciones. Por ejemplo:

$$w_{i,i+2} = V^{-1}(\mu_i - \mu_{i+2}) = V^{-1}(\mu_i - \mu_{i+1}) - V^{-1}(\mu_{i+1} - \mu_{i+2}) = w_{i,i+1} - w_{i+1,i+2}.$$

En conclusión, si $p > G-1$, el número máximo de vectores w que podemos tener es $G-1$, ya que los demás se deducen de ellos. Cuando $p \leq G-1$, como estos vectores pertenecen a R^p el número máximo de vectores linealmente independientes es p . Es importante resaltar que, como es natural, la regla de decisión obtenida cumple la propiedad transitiva. Por ejemplo, si $G=3$, y obtenemos que para un punto (x)

$$\begin{aligned} D_1^2(x) &> D_2^2(x) \\ D_2^2(x) &> D_3^2(x) \end{aligned}$$

entonces forzosamente $D^2_1(x) > D^2_3(x)$ y esta será el resultado que obtendremos si calculamos estas distancias, por lo que el análisis es coherente. Además, si $p=2$, cada una de las tres ecuaciones $A_{ij}(x)=0$ será una recta y las tres se cortarán en el mismo punto. En efecto, cualquier recta que pase por el punto de corte de las rectas $A_{12}(x)=0$ y $A_{23}(x)=0$ tiene la expresión

$$a_1 A_{12}(\mathbf{x}) + a_2 A_{23}(\mathbf{x}) = 0$$

ya que si x_0^* es el punto de corte como $A_{12}(x^*)=0$, por pertenecer a la primera recta, y $A_{23}(x^*)=0$, por pertenecer a la segunda, pertenecerá a la combinación lineal.

$$A_{13}(\mathbf{x}) = L_1(\mathbf{x}) - L_3(\mathbf{x}) = L_1(\mathbf{x}) - L_2(\mathbf{x}) + L_2(\mathbf{x}) - L_3(\mathbf{x}),$$

tenemos que:

$$A_{13}(\mathbf{x}) = A_{12}(\mathbf{x}) + A_{23}(\mathbf{x})$$

y la recta $A_{13}(x)$ debe siempre pasar por el punto de corte de las otras dos.

Procedimiento operativo

Supongamos cinco poblaciones con $p > 4$, con lo que existirán cuatro reglas de clasificación independientes y las demás se deducen de ellas. Tenemos dos formas de realizar el análisis. La primera es calcular para las G poblaciones las distancias de Mahalanobis (o lo que es equivalente, las proyecciones) y clasificar el elemento en la más próxima. La segunda es hacer el análisis comparando las poblaciones dos a dos. Supongamos que hemos obtenido de las comparaciones 2 a 2 los siguientes resultados: ($i > j$ indica que la población i es preferida a la j , es decir, el punto se encuentra más próximo a la media de la población i que a la de j):

$$1 > 2$$

$$2 > 3$$

$$4 > 3$$

$$5 > 4$$

Las poblaciones 2, 3 y 4 quedan descartadas (ya que $1 > 2 > 3$ y $5 > 4$). La duda no resuelta se refiere a las poblaciones 1 y 5.

Construyendo (a partir de las reglas anteriores) la regla para discriminar entre estas dos últimas poblaciones, supongamos que

$$5 > 1$$

y clasificaremos en la población 5. Cuando $p < G-1$ el máximo número de proyecciones linealmente independientes que podemos construir es p , y éste será el máximo número de variables a definir. Por ejemplo, supongamos que $p=2$ y $G=5$. Podemos definir una dirección de proyección cualquiera, por ejemplo

$$w_{12} = V^{-1}(\mu_1 - \mu_2)$$

y proyectar todas las medias $(\mu_1, \mu_2, \dots, \mu_5)$ y el punto x sobre dicha dirección. Entonces, clasificaremos el punto en la población de cuya media proyectada está más próxima. Ahora bien, es posible que sobre esta dirección coincidan las medias proyectadas de varias poblaciones. Si esto ocurre con, por ejemplo, las μ_4 y μ_5 , resolveremos el problema proyectando sobre la dirección definida por otra pareja de poblaciones.

Ejemplo 2 Una máquina que admite monedas realiza tres mediciones de cada moneda para determinar su valor: peso (x_1), espesor (x_2) y la densidad de estrías en su canto (x_3). Los instrumentos de medición de estas variables no son muy precisos y se ha comprobado en una amplia experimentación con tres tipos de monedas usadas, M_1, M_2, M_3 , que las medidas se distribuyen normalmente con medias para cada tipo de moneda y varianza:

$$\begin{array}{lll} \mu_1 = & 20 & 8 & 8 \\ \mu_2 = & 19.5 & 7.8 & 10 \\ \mu_3 = & 20.5 & 8.3 & 5 \end{array} \quad V = \begin{bmatrix} 4 & .8 & -5 \\ .8 & .25 & -.9 \\ -5 & -.9 & 9 \end{bmatrix}$$

Indicar cómo se clasificaría una moneda con medidas (22, 8.5 ,7) y analizar la regla de clasificación. Calcular las probabilidades de error.

Aparentemente la moneda a clasificar está más próxima a M_3 en las dos primeras coordenadas, pero más próxima a M_1 por x_3 , la densidad de estrías. La variable indicador para clasificar entre M_1 y M_3 es

$$z = (\mu_1 - \mu_3)V^{-1}\mathbf{x} = 1.77x_1 - 3.31x_2 + .98x_3$$

La media para la primera moneda, M_1 , es $1.77 \times 20 - 3.31 \times 8 + .98 \times 8 = 16.71$ y para la tercera, M_3 , $1.77 \times 20.5 - 3.31 \times 8.3 + .98 \times 5 = 13.65$. El punto de corte es la media, 15.17. Como para la moneda a clasificar es.

$$z = 1.77 \times 22 - 3.31 \times 8.5 + .98 \times 7 = 17.61$$

la clasificaremos como M_1 .

Este análisis es equivalente a calcular las distancias de Mahalanobis a cada población que resultan ser $D_1^2 = 1.84$, $D_2^2 = 2.01$ y $D_3^2 = 6.69$. Por tanto clasificamos primero en M_1 , luego en M_2 y finalmente como M_3 . La regla para clasificar entre la primera y la segunda es.

$$z = (\mu_1 - \mu_2)V^{-1}x = -.93x_1 + 1.74x_2 - .56x_3$$

de estas dos reglas deducimos inmediatamente la regla para clasificar entre la segunda y la tercera, ya que.

$$(\mu_2 - \mu_3)V^{-1}x = (\mu_1 - \mu_3)V^{-1}x - (\mu_1 - \mu_2)V^{-1}x$$

Vamos a expresar la reglas inicial para clasificar entre M_1 y M_3 para las variables estandarizadas, con lo que se evita el problema de las unidades. Llamando $\tilde{x}_i$ a las variables divididas por sus desviaciones típicas $\tilde{x}_1 = x_1/2$; $\tilde{x}_2 = x_2/.5$, y $\tilde{x}_3 = x_3/3$, la regla en variables estandarizadas es.

$$z = 3.54\tilde{x}_1 - 1.65\tilde{x}_2 + 2.94\tilde{x}_3$$

indica que las variables con más peso para decidir la clasificación son la primera y la tercera, que son la que tienen mayores coeficientes. Observemos que con variables estandarizadas la matriz de covarianzas es la de correlación.

$$R = \begin{bmatrix} 1 & .8 & -.83 \\ .8 & 1 & -.6 \\ -.83 & -.6 & 1 \end{bmatrix}$$

El origen de estas correlaciones entre los errores de medida es que si la moneda adquiere suciedad y aumenta ligeramente su peso, también aumenta su espesor y hace más difícil determinar su densidad de estrías. Por eso hay correlaciones positivas entre peso y espesor, al aumentar el peso aumenta el espesor, pero negativas con las estrías. Aunque la moneda que queremos clasificar tiene mucho peso y espesor, lo que indicaría que pertenece a la clase 3, entonces la densidad de estrías debería medirse como baja, ya que hay correlaciones negativas entre ambas medidas, y sin embargo se mide relativamente alta en la moneda. Las tres medidas son coherentes con una moneda sucia del tipo 1, y por eso se clasifica con facilidad en ese grupo.

Vamos a calcular la probabilidad a posteriori de que la observación sea de la clase M1. Suponiendo que las probabilidades a priori son iguales esta probabilidad será.

$$P(1/x_0) = \frac{\exp(-D_1^2/2)}{\exp(-D_1^2/2) + \exp(-D_2^2/2) + \exp(-D_3^2/2)}$$

y sustituyendo las distancias de Mahalanobis

$$P(1/x_0) = \frac{\exp(-1.84/2)}{\exp(-1.84/2) + \exp(-2.01/2) + \exp(-6.69/2)} = .50$$

y análogamente $P(2/x_0) = 0.46$, y $P(3/x_0) = 0.04$.

Podemos calcular las probabilidades de error de clasificar una moneda de cualquier tipo en otra clase. Por ejemplo, la probabilidad de clasificar una moneda M_3 con esta regla como tipo M_1 es

$$P(z > 15.17/N(13.64, \sqrt{3.07})) = P(y > \frac{15.17 - 13.64}{1.75}) = P(y > .87) = .192$$

como vemos esta probabilidad es bastante alta. Si queremos reducirla hay que aumentar la distancia de Mahalanobis entre las medias de los grupos, lo que supone *aumentar* la matriz V^{-1} o *reducir* la matriz V

Por ejemplo, si reducimos a la mitad el error en la medida de las estrías introduciendo medidores más precisos, pero se mantiene las correlaciones con las otras medidas, pasamos a la matriz de covarianzas.

$$V_2 = \begin{bmatrix} 4 & .8 & -2.5 \\ .8 & .25 & -.45 \\ -1 & -.2 & 2.25 \end{bmatrix}$$

la regla de clasificación entre la primera y la tercera es ahora.

$$z = (\mu_1 - \mu_3)\mathbf{V}^{-1}\mathbf{x} = 3.44x_1 - 4.57x_2 + 4.24x_3$$

y la distancia de Mahalanobis entre las poblaciones 1 y 3 (monedas M^1 y M_3) ha pasado de 3.01 a 12.38, lo que implica que la probabilidad de error entre estas dos poblaciones ha disminuido a $1 - \Phi(\sqrt{12.38}/2) = 1 - \Phi(1.76) = .04$ y vemos que la probabilidad de error ha disminuido considerablemente. Podemos así calcular la precisión en las medidas que necesitaríamos para conseguir unas probabilidades de error determinadas.