

7.1.3. ANÁLISIS DISCRIMINANTE

Definición 1. Un conjunto de elementos que pueden venir de dos o más poblaciones distintas. En cada elemento se ha observado una variable aleatoria p -dimensional $\mathbf{x}$, cuya distribución se conoce en las poblaciones consideradas. Se desea clasificar un nuevo elemento, con valores de las variables conocidas, en una de las poblaciones. El problema de discriminación aparece en muchas situaciones en que necesitamos clasificar elementos con información incompleta. En otros casos la información podría estar disponible, pero puede requerir destruir el elemento. Finalmente, en otros casos la información puede ser muy costosa de adquirir.

Por ejemplo, Los sistemas de concesión de créditos establecidos en instituciones financieras. En reconocimiento de patrones para diseñar máquinas idóneas de clasificar de manera automática los procesos. Como: reconocer voces y sonidos, clasificar billetes o monedas, reconocer caracteres escritos en una pantalla de un ordenador o clasificar cartas según el distrito postal. Determinar un texto escrito de procedencia desconocida a uno de varios autores por las frecuencias de utilización de palabras, determinar una partitura musical de un autor o un cuadro a un artista, una declaración de impuestos como potencialmente defraudadora o no, un paciente como enfermo de cáncer o no.

Definición 2. Análisis discriminante clásico debido a Fisher. Basado en la normalidad multivariante de las variables y que es óptimo bajo dicho supuesto. Si todas las variables son continuas, es frecuente que, aunque los datos originales no sean normales es posible transformar las variables para que lo sean, y los métodos pueden aplicarse a las variables transformadas.

Función lineal discriminante para poblaciones Normales: Sea f_1 y f_2 distribuciones normales con distintos vectores de medias, pero idéntica matriz de varianzas. Se desea clasificar un elemento genérico $\mathbf{x}$, que si pertenece a la población $i=1,2$ tiene función de densidad:

$$f_i(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\mathbf{V}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)' \mathbf{V}^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \right\}.$$

La partición óptima, es, clasificar en la población P_2 si:

$$\frac{f_2(\mathbf{x})\pi_2}{c(2|1)} > \frac{f_1(\mathbf{x})\pi_1}{c(1|2)}.$$

Ambos términos son positivos, tomando logaritmos y sustituyendo $f_i(\mathbf{x})$

$$-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_2)' \mathbf{V}^{-1} (\mathbf{x} - \boldsymbol{\mu}_2) + \log \frac{\pi_2}{c(2|1)} > -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_1)' \mathbf{V}^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) + \log \frac{\pi_1}{c(1|2)},$$

Llamando D_i^2 a la distancia de Mahalanobis entre el punto observado, $\mathbf{x}$, y la media de la población i :

$$D_i^2 = (\mathbf{x} - \boldsymbol{\mu}_i)' \mathbf{V}^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)$$

Podemos escribir:

$$D_1^2 - \log \frac{\pi_1}{c(1|2)} > D_2^2 - \log \frac{\pi_2}{c(2|1)}$$

Y suponiendo iguales los costes y las probabilidades a priori, $c(1/2) = c(2/1)$; $\pi_1 = \pi_2$, la regla anterior se reduce a:

$$\text{Clasificar en 2 si } D_1^2 > D_2^2$$

Es decir, clasificar la observación en la población de cuya distancia de Mahalanobis, es menor.

Por ejemplo. Se desea clasificar un retrato entre dos posibles pintores. Para ello se miden dos variables: la profundidad del trazo y la proporción que ocupa el retrato sobre la superficie del lienzo. Las medias de estas variables para el primer pintor, A, son (2 y 0.8) y para el segundo, B, (2.3 y 0.7) y las desviaciones típicas de estas variables son 0.5 y 0.1 y la correlación entre estas medidas es 0.5. La obra a clasificar tiene medidas de estas variables (2.1 y 0.75). ¿A cuál de los pintores pertenece la obra?

Calculando las distancias de Mahalanobis (la covarianza es el producto de la correlación por las desviaciones típicas):


$$D_A^2 = (2.1 - 2, .75 - .8) \begin{bmatrix} .25 & .025 \\ .025 & .01 \end{bmatrix}^{-1} \begin{pmatrix} 2.1 - 2 \\ .75 - .8 \end{pmatrix} = 0,52$$

Y para la segunda

$$D_B^2 = (2.1 - 2.3, .75 - .7) \begin{bmatrix} .25 & .025 \\ .025 & .01 \end{bmatrix}^{-1} \begin{pmatrix} 2.1 - 2.3 \\ .75 - .7 \end{pmatrix} = 0,8133$$

Por tanto, asignaremos la obra al primer pintor.

Definición 3. Con la finalidad de tener una lectura inicial del comportamiento de los datos se realiza gráficos de dispersión.



La figura en el espacio bivalente definido por las variables X_1 y X_2 , las nubes de puntos correspondientes a dos grupos hipotéticos. Los dos grupos representados se diferencian entre sí en ambas variables, pero no por completo, pues, de hecho, se solapan en una pequeña región situada entre ambos, también está representada la función D , que es una combinación lineal de ambas variables. Sobre la función D se representa la proyección de las dos nubes de puntos en forma de histograma, como si la función D cortara a las dos nubes de puntos en la dirección de su eje. Las dos líneas punteadas de cada uno de los histogramas representan los centroides del modelo. Las pruebas estadísticas más utilizadas son.

:

- Autovalor: permite comparar cómo se distribuye la dispersión Inter-grupos cuando existe más de una función, tiene un valor mínimo de cero, pero no tiene un máximo lo que hace difícil de interpretar.

Hipótesis planteada:

H_0 : Grupos parecidos o iguales

H_1 : Grupos diferentes o distintos

Si $Auvalor \rightarrow 0$, Se acepta H_0 (grupos parecidos)

Si $Auvalor \rightarrow Grande$, Se rechaza H_0 (grupos diferentes)

- Correlación canónica: Es la correlación entre la combinación lineal de las variables independientes y una combinación lineal de variables indicador. Una correlación canónica alta (60%) indica que las variables discriminantes permiten diferenciar entre los grupos.

Hipótesis planteada:

H_0 : Grupos parecidos o iguales

H_1 : Grupos diferentes o distintos

Si C. canónica $\rightarrow 0$, Se acepta H_0 (grupos parecidos)

Si C. canónica $\rightarrow 1$, Se rechaza H_0 (Grupos diferentes)

- *Lambda de Wilks* que expresa la proporción de variabilidad total no debida a las diferencias entre los grupos. Por tanto, valores de *lambda de Wilks* cercanos a 1 indican un grande parecido entre grupo, mientras que valores próximos a cero indican una gran diferencia entre ellos

Hipótesis planteada:

$H_0: \mu_1 = \mu_2 = \dots = \mu_k$; Grupos parecidos o iguales

$H_1: \mu_1 \neq \mu_2 \neq \dots \neq \mu_k$: Grupos diferentes o distintos

Si lambda de Wilks $\rightarrow 1$, Se acepta H_0 (grupos parecidos)

Si lambda de Wilks $\rightarrow 0$, Se rechaza H_0 (Grupos diferentes)

- Chi-cuadrado: Es una transformado de *lambda de Wilks*

Hipótesis planteada:

$H_0: \mu_1 = \mu_2 = \dots = \mu_k$; Grupos parecidos o iguales

$H_1: \mu_1 \neq \mu_2 \neq \dots \neq \mu_k$: Grupos diferentes o distintos

Se rechaza H_0 . Si $\alpha > \text{Sig.}$


Ejercicio práctico N°1.

Con los datos correspondientes a 30 Cortes Superiores de Justicia del Perú, medidos en seis variables: pendiente, ingresado, resueltos, personal, dependencias y población. Definido en procedimiento clúster k medias Con esta información realizar análisis discriminante.

Solución:

Para realizar análisis discriminante debe existir una variable que divida a los casos (Cortes Superior) en grupos. En este ejercicio es necesario crear una variable de agrupamiento (utilizar cual procedimiento para crear la variable de agrupamiento).


Utilizar clúster k medias, para agrupar a las Corte Superiores. Para ello, ir al menú *Analizar -> Clasificar-> clúster k*. Aquí, ingresar las variables en el cuadro de dialogo como se muestra en la imagen siguiente.



Pulse continuar y aceptar, la variable creada aparece en editor de datos (vista de datos) con el nombre de QCL_1. En vista de variable, cambie el nombre de QCL_1 por tamaño, en valor asigne 1 para pequeño, 2 para grande y obtiene el resultado siguiente.

	CorteSuperior	Pendientes	Ingresados	Resueltos	Personal	Dependencias	Población	Tamaño
1	Amazonas	,007	,011	,0110	,017	,018	,014	Pequeño
2	Ancash	,020	,020	,0210	,017	,029	,020	Pequeño
3	Apurímac	,013	,013	,0150	,016	,017	,015	Pequeño
4	Cafete	,006	,008	,0090	,015	,013	,008	Pequeño
5	Huancave	,005	,009	,0090	,009	,010	,010	Pequeño
6	Huaura	,017	,021	,0190	,022	,024	,019	Pequeño
7	MadreDios	,004	,007	,0060	,009	,012	,004	Pequeño
8	Moquegua	,007	,011	,0100	,012	,012	,006	Pequeño

Para realizar análisis discriminante elegir la opción *Analizar -> Clasificar-> Discriminante*. Aparece el cuadro de diálogo siguiente. Aquí ingrese en variable de agrupación: tamaño. En el botón *Definir rango*: mínimo 1 y máximo 2.



Pulsar el botón *continuar* para volver al cuadro de diálogo principal. Aquí, ingrese en la caja independientes: pendiente, ingresado, resueltos, personal, dependencias y población, todas las variables deben ser cuantitativa (escala). Como se muestra en la figura.

Análisis discriminante

Variable de agrupación:

Independientes:
☐ Pendientes
☐ Ingresados
☐ Resueltos
☒ Introducir independientes juntos
☐ Usar método de inclusión por pasos

Variable de selección:

Luego de realizar estas selecciones presionamos aceptar, el visor presenta los siguientes resultados.

El primer cuadro muestra un resumen con el total de los casos procesados, el número de casos válidos para el análisis y el número de casos excluidos, los que son excluidos por tener un valor perdido, y las que cumplen las dos condiciones anteriores.

Resumen de procesamiento de casos de análisis

Casos sin ponderar		N	Porcentaje
Válido		30	100,0
Excluido	Códigos de grupo perdidos o fuera de rango	0	,0
	Como mínimo, falta una variable discriminatoria	0	,0
	Faltan ambos códigos de grupo, los perdidos o los que están fuera de rango y, como mínimo, una variable discriminatoria	0	,0
	Total	0	,0
Total		30	100,0

El cuadro siguiente muestra un resumen del número de casos validos en cada variable discriminante. La información de esta tabla posee un interés especial, pues un número desigual de casos en cada uno de los grupos puede afectar a la clasificación.

Estadísticas de grupo

Tamaño de grupo		N válido (por lista)	
		No ponderados	Ponderados
Pequeño	Pendientes	22	22,000
	Ingresados	22	22,000
	Resueltos	22	22,000
	Personal	22	22,000
	Dependencias	22	22,000
	Población	22	22,000
Grande	Pendientes	8	8,000
	Ingresados	8	8,000
	Resueltos	8	8,000
	Personal	8	8,000
	Dependencias	8	8,000
	Población	8	8,000
Total	Pendientes	30	30,000
	Ingresados	30	30,000
	Resueltos	30	30,000
	Personal	30	30,000
	Dependencias	30	30,000
	Población	30	30,000

El cuadro siguiente contiene los autovalores, % de variancia, % acumulado y correlación canónica. La hipótesis H_0 : grupos pequeño es igual a grupo grande H_1 : grupos pequeño es diferente a grupo grande. El autovalor es de 3.319 es un valor grande, que permite rechaza H_0 de que los grupos

formados son diferentes. La correlación canónica es alta 87.7% indica que las variables discriminantes permiten diferenciar entre los grupos.

Autovalores

Función	Autovalor	% de varianza	% acumulado	Correlación canónica
1	3,319 ^a	100,0	100,0	,877

a. Se utilizaron las primeras 1 funciones discriminantes canónicas en el análisis.

El cuadro siguiente muestra *lambda de Wilks*. La hipótesis planteada $H_0: \mu_{\text{pequeño}} = \mu_{\text{grande}}$ y $H_1: \mu_{\text{pequeño}} \neq \mu_{\text{grande}}$. Lambda de Wilks es 0.232 es un valor cercano a cero que permite rechazar H_0 , es decir los grupos son diferentes. Chi-cuadrado, con sig. igual a 0.000 este valor es menor que 5%, se concluye que las medias son diferentes (los grupos son diferentes).

Lambda de Wilks

Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	,232	36,577	6	,000

El cuadro siguiente muestra la tabla de coeficientes de la función discriminante canónica estandarizados. Los valores indican la importancia de cada variable en la función, ingresados (0.930) es la más importante, seguido por personal (0.802)

Coeficientes de función discriminante canónica estandarizados

Función	
1	
Pendientes	,050
Ingresados	,930
Resueltos	-,088
Personal	,802
Dependencias	-,723
Población	,000

El cuadro siguiente muestra la *Matriz de estructura* que contiene las correlaciones entre las variables discriminantes y la función discriminante estandarizada. Se apreciar que ingresados (0.930) correlaciona alto con la función discriminante.

Matriz de estructuras

Función	
1	
Ingresados	,930
Resueltos	,866
Personal	,857
Pendientes	,755
Dependencias	,711
Población	,547

Correlaciones dentro de grupos combinados entre las variables discriminantes y las funciones discriminantes canónicas estandarizadas
Variables ordenadas por el tamaño absoluto de la correlación dentro de la función.


El cuadro siguiente muestra la ubicación de *los centroides en* la función discriminante. Se observar que el grupo de grande se encuentra localizado en promedio, en las puntuaciones positivas de la función, mientras que pequeño se encuentran en las puntuaciones negativas función.

Funciones en centroides de grupo


Tamaño de grupo	Función
Pequeño	-1,061
Grande	2,919

Las funciones discriminantes canónicas sin estandarizar se han evaluado en medias de grupos

Diagrama de dispersión simple, para eje y: ingresos, eje x resueltos y establecer marcas por: tamaño. Como se muestra en la gráfica.



Se obtiene el siguiente gráfico, donde se observa que los grupos son distintos. Entonces, si se puede realizar análisis discriminante.




Problema practico N° 2


Con la información de la encuesta del supermercado definido en ejercicio práctico N° 2, de capítulo II del presente libro. Agrupar a los clientes del supermercado en tres grupos, utilizando análisis clúster jerárquicos.

Solución:

Seleccionamos la opción **Analizar** -> **Clasificar**-> **Análisis Discriminante**, obteniéndose el cuadro de diálogo siguiente. Aquí, en variable de agrupación: civil, a independiente: aseo y abarrotes, como se muestra en el siguiente gráfico.



Luego debemos pulsar en el botón *Definir rango*: mínimo 1 y rango máximo 4.



Una vez ingresado los rangos, pulsar el botón *continuar* para volver al cuadro de diálogo principal. Luego presionamos aceptar. El visor presenta los siguientes resultados.

El primer cuadro muestra un resumen con el total de los casos procesados, el número de casos válidos para el análisis y el número de casos excluidos, los que son excluidos por tener un valor perdido en al menos una variable discriminante, y las que cumplen las dos condiciones anteriores. En este ejercicio no fue excluido ningún cliente.

Resumen de procesamiento de casos de análisis		
Casos sin ponderar	N	Porcentaje
Válido	30	100,0
Excluido		
Códigos de grupo perdidos o fuera de rango	0	,0
Como mínimo, falta una variable discriminatoria	0	,0
Faltan ambos códigos de grupo, los perdidos o los que están fuera de rango y, como mínimo, una variable discriminatoria	0	,0
Total	0	,0
Total	30	100,0

El cuadro siguiente muestra un resumen del número de casos validos en cada variable discriminante. La información de esta tabla posee un interés especial, pues un número desigual de casos en cada uno de los grupos puede afectar a la clasificación.

Estadísticas de grupo

		N válido (por lista)	
Estado Civil		No ponderados	Ponderados
Soltero	Venta de Artículos de Aseo Personal	5	5,000
	Venta de Abarrotes	5	5,000
Casado	Venta de Artículos de Aseo Personal	12	12,000
	Venta de Abarrotes	12	12,000
Divorciado	Venta de Artículos de Aseo Personal	4	4,000
	Venta de Abarrotes	4	4,000
Viudo	Venta de Artículos de Aseo Personal	9	9,000
	Venta de Abarrotes	9	9,000
Total	Venta de Artículos de Aseo Personal	30	30,000
	Venta de Abarrotes	30	30,000

El cuadro siguiente contiene los autovalores. El valor del autovalor es 0.282 (próximo a cero) y la correlación canónica es 0.469 (moderada) por lo que debemos suponer que las variables aseo y

abarrotes no permiten distinguir demasiado bien entre los grupos en ambas funciones (los grupos son parecidos).

Autovalores

Función	Autovalor	% de varianza	% acumulado	Correlación canónica
1	,282 ^a	85,2	85,2	,469
2	,049 ^a	14,8	100,0	,216

a. Se utilizaron las primeras 2 funciones discriminantes canónicas en el análisis.

El cuadro siguiente muestra el estadístico *lambda de Wilks*. Los valores de *lambda de Wilks* son cercanos a 1, indican grupos parecidos existe bastante solapamiento entre los grupos. Sin embargo, el valor transformado de *lambda*, *Chi-cuadrado* tiene un nivel crítico (Sig.) de 0.260 por lo que podemos aceptar la hipótesis nula de que los grupos comparados tienen promedios iguales en las dos variables discriminantes en la primera función. Para la segunda función *Chi-cuadrado* tiene un nivel crítico (Sig.) de 0.537 por lo que podemos aceptar la hipótesis nula de que los grupos comparados tienen promedios iguales en las dos variables discriminantes. En consecuencia, los grupos son parecidos y no se podrá realizar análisis discriminante.

Lambda de Wilks

Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1 a 2	,744	7,706	6	,260
2	,953	1,245	2	,537

El cuadro siguiente muestra la tabla de *coeficientes estandarizados* que contiene una versión estandarizada de los coeficientes de la función canónica discriminante. En la función 1 la venta de abarrotes (0.923) tiene mayor importancia que las ventas de aseo y en la función 2 la venta de aseo (0.779) tiene mayor importancia que las ventas de abarrotes.

Coeficientes de función discriminante canónica estandarizados

	Función	
	1	2
Venta de Artículos de Aseo Personal	-,678	,779
Venta de Abarrotes	,923	,463

El cuadro siguiente muestra *la Matriz de estructura* que contiene las correlaciones entre las variables discriminantes y la función discriminante estandarizada. La venta de abarrotes correlaciona (0.754) alto con la función discriminante 1, la venta de aseo correlaciona (0.894) alto con la función discriminante 2.

Matriz de estructuras

	Función	
	1	2
Venta de Abarrotes	,754 *	,657
Venta de Artículos de Aseo Personal	-,449	,894 *

Correlaciones dentro de grupos combinados entre las variables discriminantes y las funciones discriminantes canónicas estandarizadas. Variables ordenadas por el tamaño absoluto de la correlación dentro de la función.

*. La mayor correlación absoluta entre cada variable y cualquier función discriminante.

El cuadro siguiente muestra la ubicación de los *centroides en* la función discriminante. Esta tabla es de gran utilidad para interpretar la función discriminante. Podemos observar que el grupo de solteros y casado se encuentra localizado en promedio, en las puntuaciones positivas de la primera

función mientras que, divorciados y viudos se encuentran en las puntuaciones negativas respecto de la primera función.

Funciones en centroides de grupo

Estado Civil	Función	
	1	2
Soltero	1,025	,173
Casado	,006	-,250
Divorciado	-,437	,236
Viudo	-,383	,132

Las funciones discriminantes canónicas sin estandarizar se han evaluado en medias de grupos

Si realizamos un diagrama de dispersión para poder tener una primera lectura de los grupos. Se observa que no se pueden distinguir claramente los grupos. En consecuencia, no se posible realizar un análisis discriminante.

