

Modelos de Regresión y Series de Tiempo (MRST)

2025 - 02

Clase 11 – Validación de supuestos y criterios para detectar observaciones atípicas

Docente: Natalia Jaramillo Quiceno

Escuela de Ingenierías

natalia.jaramilloq@upb.edu.co

Regresión lineal múltiple

Validación de supuestos - Introducción



Las principales premisas que hemos hecho hasta ahora al estudiar el análisis de regresión son las siguientes:

- 1 - La relación entre la respuesta y y los regresores es lineal, al menos en forma aproximada.
 - 2 - El término de error ε tiene media cero.
 - 3 - El término de error ε tiene varianza constante.
 - 4 - Los errores no están correlacionados.
 - 5 - Los errores tienen distribución normal.
- Las hipótesis 4 y 5 implican que los errores son variables aleatorias independientes.
 - La premisa 5 se requiere para probar hipótesis y para estimar intervalos.
 - No cumplir con las premisas puede conducir a un modelo inestable.

Recordar que...

Los estadísticos de resumen t , F , R^2 o R^2_{Adj} son propiedades “globales” del modelo, y como tal no aseguran la adecuación de este.

Regresión lineal múltiple

Validación de supuestos - Introducción



Recordar...la validación de supuestos se realiza mediante el análisis de residuales.

De manera matricial, los residuales son obtenidos de la forma:

$$\mathbf{e} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$$

Lo que en forma escalar podría escribirse como

$$e_i = y_i - \hat{y}_i, \quad i = 1, 2, \dots, n$$

Regresión lineal múltiple

Validación de supuestos – Normalidad de los ε

Existen dos mecanismos para verificar el supuesto de distribución normal:

a – A través del gráfico “Q-Q” o de probabilidad normal:

Con una inspección visual se identifica si los datos se ajustan a una recta:

b – Mediante test

H_0 : Los errores se distribuyen normal

H_a : Los errores no se distribuyen normal

Pruebas analíticas disponibles:

- Shapiro-Wilks
- Kolmogorov-Smirnov
- Anderson Darling
- Cramér-con Mises


Criterio de decisión

Rechazar H_0 si:

$$\text{Valor } p < \alpha$$



CASO IDEAL





Regresión lineal múltiple

Validación de supuestos – Normalidad de los ε



Posibles resultados del gráfico de probabilidad normal



A - Caso ideal, se cumple el supuesto

No se cumple el supuesto en:

B - Colas de distribución demasiado gruesas para considerarse como normal.

C – Colas de distribución más delgadas que la normal.

D y E – Asimetría positiva y negativa.

Regresión lineal múltiple

Validación de supuestos – Varianza constante de los ε



Prueba de hipótesis :


H_0 : Los errores tiene varianza constante

H_a : Los errores NO tienen varianza constante

Principal mecanismo para verificar el supuesto de varianza constante...



CASO IDEAL



a - A través de alguno de los siguientes gráficos:

- Residuales en función de x_i .
- Residuales en función de $\hat{y}_i$.



b – Mediante test

- Breusch-Pagan

Criterio de decisión

Rechazar H_0 si:

$$\text{Valor } p < \alpha$$




Regresión lineal múltiple

Validación de supuestos – Varianza constante de los ε



Se valida utilizando gráficos de residuales vs. predichos o residuales vs. cada variable regresora. Los patrones más comunes son:



a - Caso ideal, se cumple el supuesto

No se cumple el supuesto en :

b, c, y d – La varianza de los e_i parece ser función de los valores de y .

Regresión lineal múltiple

Observaciones atípicas - Introducción



Las observaciones atípicas pueden clasificarse en:

- ❖ Puntos atípicos, pero sin influencia
- ❖ Puntos de balanceo
- ❖ Puntos influyentes

Deben identificarse y determinar su causa:

- Error de medición o registro (error humano, se pueden eliminar)
- Observaciones producto de una condición extrema (no se pueden eliminar)


Regresión lineal múltiple

Observaciones atípicas - Introducción



Puntos atípicos, pero sin influencia

- Observaciones separadas del resto de los datos y que afectan poco los resultados del ajuste del modelo de regresión.
- Tienen poca influencia en la línea de regresión ya que están próximas a $\bar{x}$



**Punto atípico,
no influyente**


Regresión lineal múltiple

Observaciones atípicas - Introducción



Puntos de balanceo

- Observaciones que, en el espacio de las predictoras, se encuentran muy alejadas del resto de la muestra (lejos de $\bar{x}$).
- Puede controlar algunas propiedades del modelo ajustado.
- Puede afectar las estadísticas de resumen del modelo (t , F , R^2 o R_{Adj}^2) y la varianza de los $\hat{\beta}_j$'s pero no afectar la estimación de los coeficientes de regresión.
- Pueden detectarse en el gráfico de dispersión.



Punto de balanceo


Regresión lineal múltiple

Observaciones atípicas - Introducción



Puntos influyentes

- Puede modificar la dirección del modelo, afectando de forma importante los coeficientes de regresión.
- Pueden detectarse en el gráfico de dispersión.




Punto influyente

Regresión lineal múltiple


Observaciones atípicas - Introducción




Gráficamente cómo se pueden identificar estas observaciones anómalas



**Punto atípico,
no influyente**



Punto de balanceo



Punto influyente

Regresión lineal múltiple

Criterios para la detección de puntos atípicos



Construir residuales escalados

Un residual escalado es un residual e_i dividido por una estimación de su error estándar.

Tipos de residuales escalados:

Residual estandarizado: $d_i = \frac{e_i}{\sqrt{MS_{\text{Res}}}}, \quad i = 1, 2, \dots, n$

La i -ésima observación será considerada atípica si $|d_i| > 3$

Residual estudentizado: $r_i = \frac{e_i}{\sqrt{MS_{\text{Res}}(1 - h_{ii})}}, \quad i = 1, 2, \dots, n$

En este caso estimamos la desviación estándar del i -ésimo residual, como $MSE * (1 - h_{ii})$, siendo h_{ii} el i -ésimo elemento en la diagonal de la matriz sombrero $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$

La i -ésima observación será considerada atípica si $|r_i| > 3$

Regresión lineal múltiple

Criterios para la detección de puntos de balanceo e influyentes



Detección de puntos de balanceo

Un punto es considerado de balanceo si $h_{ii} > \frac{2p}{n}$, con $p = k + 1$ y siendo h_{ii} el i-ésimo elemento en la diagonal de la matriz sombrero

Detección de puntos influyentes

DF BETA'S: Indica el cambio de $\hat{\beta}_j$ en unidades de desviación estándar, si se omitiera la i-ésima observación.

$$DF\ BETA_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{MSE(i) * C_{jj}}}$$

Si $|DF\ BETA_{j(i)}| > 2/\sqrt{n}$ se puede decir que la observación i es un punto influyente en la estimación del coeficiente de regresión.

$\hat{\beta}_j$: valor del parámetro j incluyendo todas las observaciones; $\hat{\beta}_{j(i)}$: valor del parámetro j sin la observación i, $MSE(i)$, estimación de la varianza del error sin la observación i.

Regresión lineal múltiple

Criterios para la detección de puntos de balanceo e influyentes



Detección de puntos influyentes (continuación)

DF FIT'S: Permite determinar la influencia de la i-ésima observación sobre el valor predicho ajustado.

Indica la cantidad de desviaciones estándar que cambia el valor ajustado $\hat{y}_i$ si se elimina la i-ésima observación.

$$DFFIT_{i(i)} = \frac{\hat{y}_i - \hat{y}_{i(i)}}{\sqrt{MSE(i) * h_{jj}}} \quad \text{Si } |DFFIT_{i(i)}| > 2 * \sqrt{p/n} \text{ se puede decir que la i-ésima observación tiene gran influencia en la estimación de } \hat{y}_i$$

$\hat{y}_i$: valor i predicho con todas las observaciones; $\hat{y}_{i(i)}$: valor i predicho sin la observación i;

$MSE(i)$ estimación de la varianza del error sin la observación i, h_{jj} : i-ésimo elemento en la diagonal de la matriz sombrero

Regresión lineal múltiple

Observaciones atípicas – Ejemplo RStudio

#detección de putos de influencia

```
print(influence.measures(mod))
```

Influence measures of
lm(formula = turistas ~ ingreso + distancia) :

	dfb.l_	dfb.ingr	dfb.dstn	dffit	cov.r	cook.d	hat	inf
1	-0.7190	0.6198	0.6874	-0.790	35.722	0.372	0.840	*
2	1.1737	-1.8684	-0.9010	-2.623	17.909	2.707	0.908	*
3	-0.1930	0.0764	0.2881	0.511	28.432	0.162	0.774	*
4	-0.0286	0.0713	-0.0644	-0.533	1.824	0.104	0.259	
5	0.2207	-0.0473	-0.1784	0.952	0.133	0.142	0.218	

DF BETA'S

DF FIT'S

h_{ii}

Regresión lineal múltiple

Bonificación

Partiendo de la base de datos **07 – riesgo.txt** y, considerando el modelo que se ha trabajado en clases previas, responda:

- ¿Se cumplen los supuestos de normalidad y varianza constante? Plantee las hipótesis para cada caso y soporte su respuesta con el procedimiento que corresponda.
- ¿Existen datos atípicos (no influyentes), de balanceo o influyentes? ¿cuáles serían dichos puntos? Soporte su respuesta con el procedimiento que corresponda.



MUCHAS GRACIAS

Natalia Jaramillo Quiceno

e-mail: natalia.jaramilloq@upb.edu.co