

CAPÍTULO 8

VARIABLES INDICADORAS

8.1 EL CONCEPTO GENERAL DE LAS VARIABLES INDICADORAS

Las variables que se emplean en el análisis de regresión se suelen llamar **variables cuantitativas**, lo que significa que las variables tienen una escala bien definida de medición. Las variables como temperatura, distancia, presión e ingreso son variables cuantitativas, **en ocasiones es necesario usar variables cualitativas o categóricas como variables predictoras en la regresión.** Como ejemplos de variables cualitativas o categóricas están los operadores, estado de empleo (empleado o desempleado), los turnos (diurno, mixto o nocturno) y el sexo (masculino o femenino). En general, una variable cualitativa no tiene escala natural de medida. **Se debe asignar un conjunto de niveles a una variable cualitativa para tener en cuenta el efecto que pueda tener la variable sobre la respuesta, esto se hace usando variables indicadoras; a veces, a las variables indicadoras se les llama variables ficticias.**

Supóngase que un ingeniero mecánico desea relacionar la vida útil y de una herramienta (un *buril*) en un torno, con la velocidad del torno, en revoluciones por minuto (x_1), y con la clase de buril que se usa. La segunda variable regresora, la clase de buril, es cualitativa y puede tener dos niveles (por ejemplo, los tipos A y B de buril). Se usará una variable indicadora que asuma los valores 0 y 1 para identificar las clases de la variable regresora “tipo de buril”, sea

$$x_2 = \begin{cases} 0 & \text{si la observación procede de la herramienta tipo A} \\ 1 & \text{si la observación procede de la herramienta tipo B} \end{cases}$$

La elección de 0 y 1 para identificar los niveles de una variable cualitativa es arbitraria. Dos valores cualesquiera distintos para x_2 serían satisfactorios, aunque por lo general los mejores son 0 y 1.

Suponiendo que es adecuado un modelo de primer orden, se tiene

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon \quad (8.1)$$

Para interpretar los parámetros en este modelo, se examinará el primer tipo de buril, el A, para el cual $x_2 = 0$. El modelo de regresión se transforma en

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 + \beta_2(0) + \varepsilon \\ &= \beta_0 + \beta_1 x_1 + \varepsilon \end{aligned} \quad (8.2)$$

Así, la relación entre la vida útil y la velocidad del torno para el buril tipo A es una recta con ordenada al origen β_0 y pendiente β_1 . Para el tipo de herramienta B, $x_2 = 1$ y

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 + \beta_2(1) + \varepsilon \\ &= (\beta_0 + \beta_2) + \beta_1 x_1 + \varepsilon \end{aligned} \quad (8.3)$$

Esto es, para el buril de tipo B, la relación entre la vida de la herramienta y la velocidad del torno también es una recta β_1 , pero con ordenada al origen $\beta_0 + \beta_2$.

Las dos funciones de respuesta se ven en la figura 8.1. Los modelos (8.2) y (8.3) describen dos líneas de regresión **paralelas**, esto es, dos rectas con una pendiente común β_1 y distintas ordenadas al origen. También, se supone que la varianza de los errores ε es igual para ambos tipos de buril, A y B. El parámetro β_2 expresa la diferencia de alturas entre las dos líneas de regresión, ya que, β_2 es una medida de la diferencia de vida media de herramienta que resulta de cambiar del tipo A al tipo B.

Se puede generalizar este método a factores cualitativos con cualquier cantidad de niveles, por ejemplo, supóngase que interesan tres tipos de herramienta: A, B y C, se requieren dos variables indicadoras, como x_2 y x_3 , para manejar los tres niveles de tipo de herramienta en el modelo. Los niveles de las variables indicadoras son

x_2	x_3	
0	0	si la observación procede del buril tipo A
1	0	si la observación procede del buril tipo B
0	1	si la observación procede del buril tipo C

y el modelo de regresión es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$$

En general, una variable cualitativa con a niveles se representa con $a - 1$ variables indicadoras, y cada una asume los valores 0 y 1.




Figura 8.1
Funciones de
respuesta para el
ejemplo de la vida
útil del buril.

Ejemplo 8.1 Datos de vida de herramienta


En la tabla 8.1 se presentan 20 observaciones de duración de herramienta y velocidad del torno, y el diagrama de dispersión se ve en la figura 8.2. Al revisar este diagrama de dispersión se ve que se requieren dos líneas de regresión para modelar bien estos datos, y que la ordenada al origen depende del tipo de herramienta que se usa; en consecuencia, se ajustará el modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

TABLA 8.1 Datos, valores ajustados y residuales para el ejemplo 8.1

i	y_i (Horas)	x_{i1} (rpm)	Tipo de herramienta	$\hat{y}_i$	e_i
1	18.73	610	A	20.7552	-2.0252
2	14.52	950	A	11.7087	2.8113
3	17.43	720	A	17.8284	-0.3984
4	14.54	840	A	14.6355	-0.0955
5	13.44	980	A	10.9105	2.5295
6	24.39	530	A	22.8838	1.5062
7	13.34	680	A	18.8927	-5.5527
8	22.71	540	A	22.6177	0.0923
9	12.68	890	A	13.3052	-0.6252
10	19.32	730	A	17.5623	1.7577
11	30.16	670	B	34.1630	-4.0030
12	27.09	770	B	31.5023	-4.4123
13	25.40	880	B	28.5755	-3.1755
14	26.05	1000	B	25.3826	0.6674
15	33.49	760	B	31.7684	1.7216
16	35.62	590	B	36.2916	-0.6716
17	26.07	910	B	27.7773	-1.7073
18	36.78	650	B	34.6952	2.0848
19	34.95	810	B	30.4380	4.5120
20	43.67	500	B	38.6862	4.9838

Figura 8.2
Gráfica de la vida útil de la herramienta y en función de la velocidad del torno x_1 , para los tipos de buril A y B.



en donde la variable indicadora $x_2 = 0$ si la observación procede de la herramienta tipo A, y $x_2 = 1$ si procede de la herramienta tipo B. La matriz $\mathbf{X}$ y el vector $\mathbf{y}$ para ajustar este modelo son

$$\mathbf{X} = \begin{bmatrix} 1 & 610 & 0 \\ 1 & 950 & 0 \\ 1 & 720 & 0 \\ 1 & 840 & 0 \\ 1 & 980 & 0 \\ 1 & 530 & 0 \\ 1 & 680 & 0 \\ 1 & 540 & 0 \\ 1 & 890 & 0 \\ 1 & 730 & 0 \\ 1 & 670 & 1 \\ 1 & 770 & 1 \\ 1 & 880 & 1 \\ 1 & 1000 & 1 \\ 1 & 760 & 1 \\ 1 & 590 & 1 \\ 1 & 910 & 1 \\ 1 & 650 & 1 \\ 1 & 810 & 1 \\ 1 & 500 & 1 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} 18.73 \\ 14.52 \\ 17.43 \\ 14.54 \\ 13.44 \\ 24.39 \\ 13.34 \\ 22.71 \\ 12.68 \\ 19.32 \\ 30.16 \\ 27.09 \\ 25.40 \\ 26.05 \\ 33.49 \\ 35.62 \\ 26.07 \\ 36.78 \\ 34.95 \\ 43.67 \end{bmatrix}$$

El ajuste por mínimos cuadrados es

$$\hat{y} = 36.986 - 0.027x_1 + 15.004x_2$$

En la tabla 8.2 se presenta el análisis de varianza y otras estadísticas de resumen para este modelo. Como el valor observado de F_0 tiene un valor P muy pequeño, se rechaza la hipótesis de significancia de la regresión, y en vista de que las estadísticas t para β_1 y β_2 tienen valores P pequeños, se llega a la conclusión de que los dos regresores, x_1 (rpm) y x_2 (tipo de herramienta) contribuyen al modelo. El parámetro β_2 es el cambio en la duración

TABLA 8.2 Estadísticas de resumen para el modelo de regresión del ejemplo 8.1

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado medio	F_0	Valor P
Regresión	1418.034	2	709.017	76.75	3.12×10^{-9}
Residual	157.055	17	9.239		
Total	1575.089	19			
Coefficiente	Estimado	Error estándar	t_0	Valor P	
β_0	36.986				
β_1	-0.027	0.005	-5.887	8.97×10^{-6}	
β_2	15.004	1.360	11.035	1.79×10^{-9}	
$R^2 = 0.9003$					




Figura 8.3
Gráfica de
residuales e_i en
función de valores
ajustados $\hat{y}_i$,
ejemplo 8.1.

promedio de la herramienta, debido a un cambio del tipo A al tipo B de herramienta. El intervalo de confianza de 95% para β_2 es

$$\begin{aligned}\hat{\beta}_2 - t_{0.025, 17} \text{se}(\hat{\beta}_2) &\leq \beta_2 \leq \hat{\beta}_2 + t_{0.025, 17} \text{se}(\hat{\beta}_2) \\ &= 15.004 - 2.110(1.360) \leq \beta_2 \leq 15.004 + 2.110(1.360)\end{aligned}$$

o sea que

$$12.135 \leq \beta_2 \leq 17.873$$

En vista de lo anterior, se tiene el 95% de confianza que al cambiar del tipo de buril A al B aumenta la duración de la herramienta entre 12.135 horas y 17.873 horas.

Los valores ajustados $\hat{y}_i$ y los residuales e_i de este modelo se ven en las dos últimas columnas de la tabla 8.1. En la figura 8.3 se muestra la gráfica de los residuales en función de $\hat{y}_i$; en esta gráfica, se identifican por tipo de herramienta (A o B); si la varianza de los errores no fuera la misma para los dos tipos, se vería en esta gráfica. Nótese que los residuales “B” en la figura 8.3 muestran un poco más dispersión que los “A”, y eso implica que puede haber un problema moderado de desigualdad de varianza. La figura 8.4 es la gráfica de probabilidad normal de los residuales. No hay indicios de inadecuación grave del modelo.

En vista de que se emplean dos líneas de regresión distintas para modelar la relación entre la vida útil del buril y la velocidad del torno, desde el principio se podrían haber ajustado dos modelos separados rectilíneos, en lugar de uno solo con una variable indicadora. Sin embargo, se prefiere el método con un solo modelo, porque el analista sólo tiene una ecuación final con la que trabajar, y no dos; es un resultado práctico mucho más simple, además, como se supone que las dos rectas tienen la misma pendiente, tiene sentido combinar los datos de ambos tipos para producir un solo estimado de este parámetro común; este método también proporciona una estimación de la varianza común del error σ^2 , y se tienen más grados de libertad que los que resultarían de ajustar dos líneas separadas de regresión.

Ahora supóngase que se espera que las rectas de regresión que relacionan la vida útil del buril con la velocidad del torno difieren tanto en la ordenada al origen como en




Figura 8.4
Gráfica de probabilidad normal de los residuales, ejemplo 8.1.

la pendiente. Es posible modelar este caso con una sola ecuación de regresión, usando variables indicadoras. El modelo es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \varepsilon \quad (8.4)$$

Al comparar la ecuación (8.4) con la (8.1) se observa que se agregó al modelo un producto cruzado entre x_1 , la velocidad del torno y la variable indicadora que representa el tipo de buril, x_2 . Para interpretar los parámetros en este modelo, se examinará primero la herramienta tipo A, para la cual $x_2 = 0$. El modelo (8.4) se transforma en

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 + \beta_2(0) + \beta_3 x_1(0) + \varepsilon \\ &= \beta_0 + \beta_1 x_1 + \varepsilon \end{aligned} \quad (8.5)$$

que es una recta con ordenada al origen β_0 y pendiente β_1 . Para el buril tipo B, $x_2 = 1$ y

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 + \beta_2(1) + \beta_3 x_1(1) + \varepsilon \\ &= (\beta_0 + \beta_2) + (\beta_1 + \beta_3)x_1 + \varepsilon \end{aligned} \quad (8.6)$$

Es un modelo rectilíneo con ordenada al origen $\beta_0 + \beta_2$ y pendiente $\beta_1 + \beta_3$. Las dos funciones de regresión se grafican en la figura 8.5. Nótese que la ecuación (8.4) define dos rectas de regresión con distintas pendientes y ordenadas al origen. En consecuencia, el parámetro β_2 refleja el cambio de ordenada al origen asociado con el cambio de buril tipo A a buril tipo B (las clases 0 y 1 de la variable indicadora x_2), y β_3 indica el cambio de pendiente asociado con el cambio de tipos de herramienta, de A a B.

El ajuste del modelo (8.4) equivale a ajustar dos ecuaciones de regresión separadas. Una ventaja del uso de variables indicadoras es que las pruebas de hipótesis se pueden hacer en forma directa, con el método de la suma extra de cuadrados. Por ejemplo, para probar si los dos modelos de regresión son idénticos, las hipótesis serían

$$H_0: \beta_2 = \beta_3 = 0$$

$$H_1: \beta_2 \neq 0 \text{ y/o } \beta_3 \neq 0.$$

$$F_0 = \frac{SS_R(\beta_2, \beta_3 | \beta_1, \beta_0) / 2}{MS_{Res}}$$




Figura 8.5
Funciones de
respuesta para la
ecuación (8.4).

En vista de que

$$\begin{aligned} SS_R(\beta_2, \beta_3 | \beta_1, \beta_0) &= SS_R(\beta_1, \beta_2, \beta_3 | \beta_0) - SS_R(\beta_1 | \beta_0) \\ &= 1434.112 - 293.005 \\ &= 1141.107 \end{aligned}$$

la estadística de prueba es

$$F_0 = \frac{SS_R(\beta_2, \beta_3 | \beta_1, \beta_0) / 2}{MS_{Res}} = \frac{1141.107 / 2}{8.811} = 64.75$$

TABLA 8.3 Estadísticas de resumen para el modelo de regresión de la vida útil de herramientas, en el ejemplo 8.2

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado medio	F_0	Valor F
Tratamientos	1434.112	3	478.037	54.25	1.32×10^{-9}
Error	140.976	16	8.811		
Total	1575.088	19			

Coefficiente	Estimado	Error estándar	t_0	Suma de cuadrados
β_0	32.775			
β_1	-0.021	0.0061	-3.45	$SS_R(\beta_1 \beta_0) = 293.005$
β_2	23.971	6.7690	3.54	$SS_R(\beta_2 \beta_1, \beta_0) = 1125.029$
β_3	-0.012	0.0088	-1.35	$SS_R(\beta_3 \beta_2, \beta_1, \beta_0) = 16.078$
$R^2 = 0.9105$				

y como el valor P para esta estadística es $P = 2.14 \times 10^{-8}$, se concluye que los dos modelos de regresión no son idénticos. Para probar la hipótesis que las dos rectas tienen distintas ordenadas al origen y una pendiente común ($H_0: \beta_3 = 0$) se usa la estadística

$$F_0 = \frac{SS_R(\beta_3 | \beta_2, \beta_1, \beta_0)/1}{MS_{\text{Res}}} = \frac{16.078}{8.811} = 1.82$$

y como el valor P para esta estadística es $P = 0.20$, se llega a la conclusión de que las pendientes de las dos rectas son iguales. Esto también se puede determinar con la estadística t para β_2 y β_3 en la tabla 8.3.

Las variables indicadoras son útiles en diversos casos de regresión. Ahora se presentarán más aplicaciones características de ellas.

Ejemplo 8.3 Una variable indicadora con más de dos niveles

Una empresa eléctrica está investigando el efecto que tiene el tamaño de la vivienda familiar y el tipo del acondicionamiento de aire que se usa en ella, sobre el consumo total de electricidad durante los meses calurosos. Sea y el consumo eléctrico total (en kilowatt-horas), durante el periodo de junio a septiembre, y x_1 el tamaño de la casa (pies cuadrados de construcción). Hay cuatro tipos de sistemas de acondicionamiento de aire: 1) sin acondicionamiento, 2) unidades de ventana, 3) bomba térmica, y 4) acondicionamiento central. Los cuatro niveles de ese factor se pueden modelar con tres variables indicadoras, x_2 , x_3 y x_4 , que se definen como sigue:

Tipo de acondicionamiento de aire	x_2	x_3	x_4
Sin acondicionamiento de aire	0	0	0
Unidades de ventana	1	0	0
Bomba térmica	0	1	0
Acondicionamiento central de aire	0	0	1

El modelo de regresión es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon \quad (8.7)$$

Si la casa no tiene acondicionamiento de aire, la ecuación (8.7) se transforma en

$$y = \beta_0 + \beta_1 x_1 + \varepsilon$$

Si la casa tiene unidades de ventanas, entonces

$$y = (\beta_0 + \beta_2) + \beta_1 x_1 + \varepsilon$$

Si la casa tiene bomba térmica, el modelo de regresión es

$$y = (\beta_0 + \beta_3) + \beta_1 x_1 + \varepsilon$$

y si la casa tiene acondicionamiento central, entonces

$$y = (\beta_0 + \beta_4) + \beta_1 x_1 + \varepsilon$$

Así, en el modelo (8.7) se supone que la relación entre el consumo eléctrico en tiempo caluroso, y el tamaño de la casa es lineal, y que la pendiente no depende del tipo de sistema de acondicionamiento de aire que se emplee. Los parámetros β_2 , β_3 y β_4 modifican la altura (u ordenada al origen) del modelo de regresión para los distintos sistemas de acondicionamiento de aire. Esto es, β_2 , β_3 y β_4 miden el efecto de las unidades de ventana, de bomba térmica y de acondicionamiento central, respectivamente, en comparación con la falta de acondicionamiento de aire; además, se pueden determinar otros efectos comparando en forma directa los coeficientes adecuados de regresión. Por ejemplo, $\beta_3 - \beta_4$ refleja la eficiencia relativa de una bomba térmica respecto al acondicionamiento central de aire, también nótese la hipótesis que la varianza del consumo de energía no depende del tipo de sistema de acondicionamiento usado; esta hipótesis puede ser inadecuada.

En este problema parece irreal suponer que la pendiente de la función de regresión que relaciona el consumo eléctrico medio con el tamaño de la vivienda no depende del tipo de sistema de acondicionamiento de aire. Por ejemplo, cabría esperar que el consumo eléctrico medio aumentará al aumentar el tamaño de la casa, pero la tasa de aumento debería ser distinta para un sistema central de acondicionamiento de aire que para las unidades de ventana, porque el primero debería ser más eficiente que las unidades de ventana para las casas más grandes. Esto es, debería haber una **interacción** entre el tamaño de la casa y la clase de sistema de acondicionamiento. Esto se puede incorporar al modelo ampliando la ecuación (8.7) para incluir términos de interacción. El modelo resultante es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_1 x_2 + \beta_6 x_1 x_3 + \beta_7 x_1 x_4 + \varepsilon \quad (8.8)$$

Los cuatro modelos de regresión, que corresponden a las cuatro clases de sistema de acondicionamiento de aire son:

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 + \varepsilon_1 && \text{(sin acondicionamiento de aire)} \\ y &= (\beta_0 + \beta_2) + (\beta_1 + \beta_5) x_1 + \varepsilon && \text{(unidades de ventana)} \\ y &= (\beta_0 + \beta_3) + (\beta_1 + \beta_6) x_1 + \varepsilon && \text{(bomba térmica)} \\ y &= (\beta_0 + \beta_4) + (\beta_1 + \beta_7) x_1 + \varepsilon && \text{(acondicionamiento central de aire)} \end{aligned}$$

Nótese que el modelo (8.8) implica que cada clase de sistema de acondicionamiento de aire puede tener una recta separada de regresión, con su pendiente y ordenada al origen correspondientes.

Ejemplo 8.4 Más de una variable indicadora

Con frecuencia hay varias variables cualitativas diferentes que se deben incorporar al modelo. Para ilustrarlo, supóngase que en el ejemplo 8.1 se debe considerar un segundo factor cualitativo, el tipo de lubricante de corte que se usa, suponiendo que este factor tiene dos niveles, se puede definir una segunda variable indicadora, x_3 , como sigue:

$$x_3 = \begin{cases} 0 & \text{si se usa aceite de baja viscosidad} \\ 1 & \text{si se usa aceite de viscosidad intermedia} \end{cases}$$

Un modelo de regresión que relacione la vida útil de la herramienta (y) con la velocidad de corte (x_1), el tipo de herramienta (x_2) y el tipo de lubricante de corte (x_3) es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon \quad (8.9)$$

Es claro que la pendiente β_1 del modelo de regresión que relaciona la vida de la herramienta con la velocidad de corte no depende ni del tipo de herramienta ni del tipo de lubricante de corte. La ordenada al origen de la recta de regresión sí depende de esos factores, en una forma aditiva.

Se pueden agregar diversos tipos de efecto de interacción al modelo. Por ejemplo, supóngase que se consideran interacciones entre la velocidad de corte y los dos factores cualitativos, por lo que el modelo (8.9) se transforma en

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_1 x_2 + \beta_5 x_1 x_3 + \varepsilon \quad (8.10)$$

Lo anterior conlleva la siguiente situación:

Tipo de buril	Lubricante de corte	Modelo de regresión
A	Baja viscosidad	$y = \beta_0 + \beta_1 x_1 + \varepsilon$
B	Baja viscosidad	$y = (\beta_0 + \beta_2) + (\beta_1 + \beta_4) x_1 + \varepsilon$
A	Viscosidad intermedia	$y = (\beta_0 + \beta_3) + (\beta_1 + \beta_5) x_1 + \varepsilon$
B	Viscosidad intermedia	$y = (\beta_0 + \beta_2 + \beta_3) + (\beta_1 + \beta_4 + \beta_5) x_1 + \varepsilon$

Nótese que cada combinación de tipo de buril y de lubricante de corte da como resultado una línea de regresión aparte, con distintas pendientes y ordenadas al origen, sin embargo, el modelo sigue siendo aditivo con respecto a los niveles de las variables de regresión. Esto es, al cambiar el lubricante de corte de viscosidad baja a intermedia, la ordenada al origen cambia en β_3 , y la pendiente en β_5 , independientemente de la clase de buril que se use.

Supóngase que se agrega un término de producto cruzado, que implica las dos variables indicadoras x_2 y x_3 al modelo, y se obtiene

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_1 x_2 + \beta_5 x_1 x_3 + \beta_6 x_2 x_3 + \varepsilon \quad (8.11)$$

En este caso se obtiene lo siguiente:

Tipo de buril	Lubricante de corte	Modelo de regresión
A	Baja viscosidad	$y = \beta_0 + \beta_1 x_1 + \varepsilon$
B	Baja viscosidad	$y = (\beta_0 + \beta_2) + (\beta_1 + \beta_4) x_1 + \varepsilon$
A	Viscosidad intermedia	$y = (\beta_0 + \beta_3) + (\beta_1 + \beta_5) x_1 + \varepsilon$
B	Viscosidad intermedia	$y = (\beta_0 + \beta_2 + \beta_3 + \beta_6) + (\beta_1 + \beta_4 + \beta_5) x_1 + \varepsilon$

La adición del término de producto cruzado $\beta_6 x_2 x_3$ en la ecuación (8.11) da como resultado que el efecto de una variable indicadora sobre la ordenada al origen dependa del nivel de la otra variable indicadora, lo que significa que al cambiar el lubricante de corte de viscosidad baja a intermedia, cambia la ordenada al origen en β_3 , si se usa el buril del tipo A, pero ese mismo cambio de lubricante de corte cambia la ordenada al origen en $\beta_3 + \beta_6$

si se usa el buril del tipo B. Si se agregara un término de interacción $\beta_7 x_1 x_2 x_3$ al modelo (8.11), entonces al cambiar el lubricante de corte de viscosidad baja a viscosidad intermedia tendría un efecto **tanto** en la ordenada al origen **como** en la pendiente, y ese efecto dependería de la clase de buril empleado.

A menos que se disponga de información anterior sobre el efecto esperado del tipo de buril y de la viscosidad del lubricante de corte sobre la duración de la herramienta, habrá que dejar que los datos guíen a uno para seleccionar la forma correcta del modelo. Esto se puede hacer, en general, probando hipótesis sobre los coeficientes individuales de regresión, aplicando la prueba F parcial. Por ejemplo, la prueba de $H_0: \beta_6 = 0$ para el modelo (8.11) permitiría discriminar entre los dos modelos candidato, el (8.11) y el (8.10).

Ejemplo 8.5 Comparación de modelos de regresión

Se examinará el caso de la regresión lineal simple, en el que las n observaciones se pueden dividir en M grupos, y el m -ésimo grupo tiene n_m observaciones. El modelo más general consiste en M ecuaciones separadas, como por ejemplo

$$y = \beta_{0m} + \beta_{1m}x + \varepsilon, \quad m = 1, 2, \dots, M \quad (8.12)$$

Con frecuencia interesa comparar este modelo general con uno más restrictivo; las variables indicadoras son útiles en este respecto. Se considerarán los siguientes casos:

a. Líneas paralelas En este caso todas las M pendientes son idénticas, $\beta_{11} = \beta_{12} = \dots = \beta_{1M}$, pero las ordenadas al origen pueden ser distintas, nótese que ésta es la clase de problema que se vio en el ejemplo 8.1 (en donde $M = 2$); condujo al uso de una variable indicadora. En forma más general se puede aplicar el método de la suma extra de cuadrados para probar la hipótesis $H_0: \beta_{11} = \beta_{12} = \dots = \beta_{1M}$. Recuérdese que este procedimiento implica ajustar un **modelo completo (FM)** y un **modelo reducido (RM)** restringido a la hipótesis nula, y calcular la estadística F :

$$F_0 = \frac{[SS_{\text{Res}}(RM) - SS_{\text{Res}}(FM)] / (df_{RM} - df_{FM})}{SS_{\text{Res}}(FM) / df_{FM}} \quad (8.13)$$

Si el modelo reducido es tan satisfactorio como el modelo completo, entonces F_0 será pequeña en comparación con $F_{\alpha, df_{RM} - df_{FM}, df_{FM}}$. Los valores grandes de F_0 implican que el modelo reducido es inadecuado.

Para ajustar el modelo completo (8.12) tan sólo se ajustan M ecuaciones separadas de regresión, a continuación se calcula $SS_{\text{Res}}(FM)$ sumando las sumas de cuadrados de residuales obtenidas en cada regresión separada. Los grados de libertad para $SS_{\text{Res}}(FM)$ son $df_{FM} = \sum_{m=1}^M (n_m - 2) = n - 2M$. Para ajustar el modelo reducido se definen $M - 1$ variables indicadoras, $D_1, D_2, \dots, D_{M-1}$ que corresponden a los M grupos, y entonces se ajusta

$$y = \beta_0 + \beta_1 x + \beta_2 D_1 + \beta_3 D_2 + \dots + \beta_M D_{M-1} + \varepsilon$$

La suma de cuadrados de residuales de este modelo es $SS_{\text{Res}}(RM)$ con $df_{RM} = n - (M + 1)$ grados de libertad.

Si la prueba F , ecuación (8.13) indica que los M modelos de regresión tienen una pendiente común, entonces $\hat{\beta}_1$ obtenida en el modelo reducido es un estimado de este parámetro, que se determina agrupando o combinando todos los datos, esto se ilustró en el

ejemplo 8.1. En forma más general, el **análisis de covarianza** se usa para agrupar los datos para estimar la pendiente común. En consecuencia, el análisis de covarianza es un tipo especial de modelo lineal, que es una combinación de un modelo de regresión (con factores cuantitativos) con un modelo de análisis de varianza (con factores cualitativos). Para conocer una introducción al análisis de covarianza, véase Montgomery [1997].

b. Líneas concurrentes. En esta sección, las M ordenadas al origen son iguales, $\beta_{01} = \beta_{02} = \dots = \beta_{0M}$, pero las pendientes pueden ser distintas. El modelo reducido es

$$y = \beta_0 + \beta_1 x + \beta_2 Z_1 + \beta_2 Z_2 + \dots + \beta_M Z_{M-1} + \varepsilon$$

en donde $Z_k = xD_k$, $k = 1, 2, \dots, M-1$. La suma de cuadrados de residuales de este modelo es $SS_{\text{Res}}(RM)$ y $df_{RM} = n - (M + 1)$ grados de libertad, nótese que se está suponiendo la concurrencia en el origen. El caso más general, de concurrencia en cualquier punto x_0 , se describe en Graybill [1976] y en Seber [1977].

c. Líneas coincidentes En este caso las M pendientes y las M ordenadas al origen son iguales, es decir, $\beta_{01} = \beta_{02} = \dots = \beta_{0M}$, y $\beta_{11} = \beta_{12} = \dots = \beta_{1M}$. El modelo reducido es tan sólo

$$y = \beta_0 + \beta_1 x + \varepsilon$$

y la suma de cuadrados de residuales $SS_{\text{Res}}(RM)$ tiene $df_{RM} = n - 2$ grados de libertad. No son necesarias variables indicadoras en la prueba de coincidencia, pero se incluye este caso para completar la explicación.

8.2 COMENTARIOS SOBRE EL USO DE VARIABLES INDICADORAS

8.2.1 Variables indicadoras en función de la regresión con códigos asignados

Otro método para manejar una variable cualitativa en regresión es medir los niveles de la variable mediante un código asignado. Recuerdese que en el ejemplo 8.3, donde se está investigando el efecto del tamaño de la vivienda y la clase de sistema de acondicionamiento de aire sobre el consumo residencial, por parte de una empresa eléctrica. En lugar de usar tres variables indicadoras para representar los cuatro niveles del factor cualitativo clase de sistema de acondicionamiento de aire, se podría usar un factor cuantitativo, x_2 , con el siguiente código asignado:

Tipo de acondicionamiento de aire	x_2
Sin acondicionamiento de aire	1
Unidades de ventana	2
Bombas térmicas	3
Acondicionamiento central de aire	4

Ahora se puede ajustar el modelo de regresión

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon \quad (8.14)$$